

MPC公式推导笔记

ColaForced

October 4, 2021

1. 最优控制 为了系统在有约束条件下，系统某项表现达到最优，一般用代价函数最小表示。比如说，火箭升空燃料代价最小，如何设计控制输入。值得一提的是，选定目标不同，计算出的控制输入也不同，比如说，追求快速升空，则控制输入势必是往油门最大化。

对于一个多目标相互约束问题，如汽车变道，一方面要求轨迹误差尽可能小，另一方面要求侧向控制输入尽可能小（为了舒适度）。在这种情况下，代价函数则是线性带权重的组合：

$$J = \int_0^t qe(s)^2 + ru(s)^2 ds \quad (1)$$

其中， u, e 分别表示控制输入和追踪误差的。 q, r 权重用于调整系统表现。

对于一般线性系统，则可以表现为

$$J = \int_0^t E^T Q E + U^T R U ds \quad (2)$$

对于这样的二次型最优化问题，应该是有相对成体系的计算方案。

2. MPC算法 对于一个离散线性系统：

$$X_{k+1} = A X_k + B U_k \quad (3)$$

显然，若已知初始条件 X_k 和控制输入 U_k ，则势必可以计算出 X_{k+1} 。

计算思路：

1. 观测/估计 k 时刻状态
2. 最小化代价函数来设计输入，代价函数是

$$J = \sum_k^{N-1} (E_k^T Q E_k + U_k^T R U_k) + E_N^T F E_N \quad (4)$$

3. 仅用计算出的最优 U_k 作为输入，然后再次循环。

Tips: 称之为滚动时域优化。

3. MPC代价函数公式推导变形 目标，滚动时域优化，当前难点在于解决最小化代价函数怎么计算。既已知道LQR中二次型优化问题怎么计算，so，当前思想就是想把MPC中的优化问题转化成二次型的形式。

先做一些声明：

$$\hat{X}_k = [X_{(k|k)}, X_{(k+1|k)}, \dots, X_{(k+N|k)}]^T \quad (5)$$

$$\hat{U}_k = [U_{(k|k)}, U_{(k+1|k)}, \dots, U_{(k+N-1|k)}]^T \quad (6)$$

其中 $X_{(k|k)} = X_k$ 表示初始状态, $X_{(k+1|k)}$ 则是根据(??)和 $U_{(k|k)}, X_k$ 计算出来的, 相应地, $X_{(k+1|k)}, \dots, X_{(k+N|k)}$ 是进一步迭代计算得到的。

误差函数定义:

$$J = \sum_k^{N-1} (X_{(K+i|k)}^T Q X_{(K+i|k)} + U_{(k+i|k)}^T R U_{(K+i|k)}) + X_{(k+N)}^T F X_{(k+N)} \quad (7)$$

为了带着目的去看推导, 先给出最后推导出的代价函数形式:

$$J = \hat{X}_k^T G \hat{X}_k + \hat{U}_k^T H \hat{U}_k + 2 \hat{X}_k^T E \hat{U}_k \quad (8)$$

可以看到, 就是为了转换成二次型的形式, 把累加项转换成 \hat{X}_k, \hat{U}_k 整体项。

so, 既然结果看到了, 加上能用的信息显然就是动态模型(??)了, 那么, 就代公式吧!

$$\left\{ \begin{array}{l} X_{(k|k)} = X_k, \\ X_{(k+1|k)} = A X_k + B U_{k|K}, \\ X_{(k+2|k)} = A^2 X_k + A B U_{k|K} + B U_{k+1|K}, \\ \dots, \\ X_{(k+N|k)} = A^N X_k + A^{N-1} B U_{k|K} + \dots + B U_{k+N-1|K} \end{array} \right. \quad (9)$$

把上式转换成

$$\hat{X}_k = M \hat{X}_k + C \hat{U}_k \quad (10)$$

其中,

$$M = \begin{bmatrix} I \\ A \\ A^2 \\ \vdots \\ A^N \end{bmatrix}, \quad (11)$$

$$C = \begin{bmatrix} 0 & 0 & \dots & 0 \\ B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ \vdots & \vdots & \vdots & B \\ A^{N-1}B & A^{N-2}B & \dots & \dots \end{bmatrix}, \quad (12)$$

在回顾公式(??), 对其展开, 再合并, 可以得到

$$J = \hat{X}_k^T \bar{Q} \hat{X}_k + \hat{U}_k^T \bar{R} \hat{U}_k \quad (13)$$

其中,

$$\bar{Q} = \begin{bmatrix} Q & 0 & 0 & \dots & 0 \\ 0 & Q & 0 & \dots & 0 \\ 0 & 0 & Q & 0 & 0 \\ \vdots & \vdots & 0 & \vdots & 0 \\ 0 & 0 & 0 & 0 & F \end{bmatrix}, \quad (14)$$

$$\bar{R} = \begin{bmatrix} R & 0 & 0 & \dots & 0 \\ 0 & R & 0 & \dots & 0 \\ 0 & 0 & R & 0 & 0 \\ \vdots & \vdots & 0 & \vdots & 0 \\ 0 & 0 & 0 & 0 & R \end{bmatrix}, \quad (15)$$

再把上式(??)带入(??)可以得到：

$$J = \hat{X}_k^T M^T \bar{Q} M \hat{X}_K + \hat{X}_k^T M^T \bar{Q} C \hat{U}_k + \hat{U}_k^T C^T \bar{Q} M^T \hat{X}_k + \hat{U}_k^T C^T \bar{Q} C \hat{U}_k + \hat{U}_k^T \bar{R} \hat{U}_k \quad (16)$$

再简化成(??)即可。

4. 学习来源 <https://www.bilibili.com/video/BV1SQ4y1Y7FG>

神仙UP主DR_CAN，我愿称之为YYDS!!!